

两团队零和博弈下熵引导的极小极大值分解强化学习方法

胡光政^{1,2} 朱圆恒^{1,2} 赵冬斌^{1,2}

摘要 在两团队零和马尔科夫博弈中, 一组玩家通过合作与另一组玩家进行对抗. 由于对手行为的不确定性和复杂的团队内部合作关系, 在高采样成本的任务中快速识别优势的分布式策略仍然具有挑战性. 鉴于此, 提出一种熵引导的极小极大值分解 (Entropy-guided minimax factorization, EGMF) 强化学习方法, 在线学习队内合作和队间对抗的策略. 首先, 提出基于极小极大值分解的多智能体执行器-评估器框架, 在高采样成本的、不限动作空间的任務中, 提升优化效率和博弈性能; 其次, 引入最大熵使智能体可以更充分地探索状态空间, 避免在线学习过程收敛到局部最优; 此外, 策略在时间域累加的熵值用于评估策略的熵, 并将其与分解的个体独立 Q 函数结合用于策略改进; 最后, 在多种博弈仿真场景和一个实体机器人任务平台上进行方法验证, 并与其他基线方法进行比较. 结果显示 EGMF 可以在更少样本下学到更具有对抗性能的两团队博弈策略.

关键词 多智能体深度强化学习, 两团队零和马尔科夫博弈, 最大熵, 值分解

引用格式 胡光政, 朱圆恒, 赵冬斌. 两团队零和博弈下熵引导的极小极大值分解强化学习方法. 自动化学报, 2025, 51(4): 875–889

DOI 10.16383/j.aas.c240258

CSTR 32138.14.j.aas.c240258

Entropy-guided Minimax Factorization for Reinforcement Learning in Two-team Zero-sum Games

HU Guang-Zheng^{1,2} ZHU Yuan-Heng^{1,2} ZHAO Dong-Bin^{1,2}

Abstract In two-team zero-sum Markov games, a group of players collaborates and confronts a team of adversaries. Due to the uncertainty of opponent behavior and the complex cooperation within teams, quickly identifying advantageous distributed policies in high-sampling-cost tasks remains challenging. This paper introduces the entropy-guided minimax factorization (EGMF) reinforcement learning method, which enables online learning of cooperative policies within teams and competitive policies between teams. Firstly, a multi-agent actor-critic framework based on minimax factorization is proposed to enhance optimization efficiency and game performance in tasks with high sampling costs and unrestricted action spaces. Secondly, maximum entropy is introduced to allow agents to explore the state space more comprehensively, preventing the online learning process from converging to local optima. In addition, the entropy of the strategy is also summed along the time domain for evaluation, which is combined with the decomposed individual independent Q function for policy improvement. Finally, experiments are conducted in some game simulated scenarios and a real-robot platform, comparing EGMF with other baseline methods. The results demonstrate that EGMF can learn more adversarial two-team game strategies with relatively fewer samples.

Key words Multi-agent deep reinforcement learning, two-team zero-sum Markov games, maximum entropy, factorization

Citation Hu Guang-Zheng, Zhu Yuan-Heng, Zhao Dong-Bin. Entropy-guided minimax factorization for reinforcement learning in two-team zero-sum games. *Acta Automatica Sinica*, 2025, 51(4): 875–889

收稿日期 2024-05-10 录用日期 2024-10-05

Manuscript received May 10, 2024; accepted October 5, 2024

国家自然科学基金 (62293541, 62136008), 北京市自然科学基金 (4232056), 北京市科技新星计划 (20240484514), 中国科学院“全球共性挑战专项” (104GJHZ2022013GC) 资助

Supported by National Natural Science Foundation of China (62293541, 62136008), Beijing Natural Science Foundation (4232056), Beijing Nova Program of Science and Technology (20240484514), and International Partnership Program of Chinese Academy of Sciences (104GJHZ2022013GC)

本文责任编辑 杨涛

Recommended by Associate Editor YANG Tao

1. 中国科学院大学人工智能学院 北京 100049 2. 中国科学院自动化研究所多模态人工智能系统全国重点实验室 北京 100190

1. School of Artificial Intelligence, University of Chinese Academy of Sciences, Beijing 100049 2. State Key Laboratory of Multi-modal Artificial Intelligence Systems, Institute of Automation, Chinese Academy of Sciences, Beijing 100190

两人零和博弈一直是人工智能领域关注的核心问题. 近年来, 随着深度强化学习等新技术的崛起和计算能力的飞速提升, 围棋^[1-2]、德州扑克^[3]和实时游戏^[4]等两人零和博弈中的一些难题的解决方案已经取得巨大进展. 然而许多现实场景通常涉及两个团队之间的对抗, 并同时涉及团队内部智能体的合作, 此类场景通常建模为两团队零和马尔科夫博弈^[5]. 近年来, 多智能体强化学习 (Multi-agent reinforcement learning, MARL) 在多智能体系统领域大放异彩, 特别是在两团队零和马尔科夫博弈应用方面已取得令人瞩目的成功, 例如在复杂游戏《星

际争霸》^[6]、《王者荣耀》^[7] 等中的竞技模式。

许多现有方法将两团队零和马尔科夫博弈简化为两人零和博弈问题进行求解, 如基于类似 Bellman 算子估计纳什均衡 (Nash equilibrium, NE) 的方法, 其在每个特定状态下解决阶段性博弈的纳什均衡问题^[8-9]。虽然在理论上可以通过多项式时间的线性规划来解决双人零和博弈的纳什均衡问题, 但随着玩家数量的增加, 其优化过程不可避免地会遇到组合爆炸问题^[10]。基于策略种群的多智能体强化学习方法 (Population-based multi-agent reinforcement learning, PB-MARL) 将多智能体强化学习与动态种群选择方法相结合^[11], 通过自动课程学习进行求解两人零和博弈问题。此类方法在很多场景中得到广泛应用, 除游戏环境, 还包括《空战》^[12-13] 和《机器人足球》^[14] 等实际应用。基于此, 一些工作将 PB-MARL 与合作的多智能体强化学习算法相结合, 以解决两团队零和马尔科夫博弈问题^[15-16]。然而, 该类方法数据利用率低, 使得在很多样本采集成本高的任务中无法应用。基于值分解的多智能体极小极大 Q 学习 (Factorized multi-agent minimax Q-learning, FM3Q)^[17] 方法大大缓解了上述问题, 在解决队间对抗的同时, 还考虑队内信誉分配的问题, 增加数据利用率, 降低计算复杂度。但 FM3Q 只能解决离散动作问题, 无法应用到连续动作场景。

为高效地解决不限动作空间的两团队零和马尔科夫博弈任务, 本文将多智能体执行器-评估器框架与极小极大值分解框架相结合, 降低两团队联合极小极大 Q 函数的训练难度, 并潜在地缓解信誉分配问题。此外, 为避免在训练过程中陷入局部最优, 引入最大熵评估并将其与分解的个体独立 Q 函数相结合用于策略改进。本文的贡献如下:

1) 为解决不限动作空间的两团队零和马尔科夫博弈任务, 本文提出一种基于极小极大值分解多智能体执行器-评估器框架, 显式构造基于神经网络的策略评估器和执行器, 同时将联合极小极大 Q 函数分解为个体独立 Q 函数用于策略评估, 引导执行器生成不限动作空间的策略, 可以在不限动作空间的任務中提升优化效率和算法性能。

2) 在上述框架中引入最大熵以防止在线学习过程收敛到局部最优。统计策略在时间域累加的熵值用于评估策略的熵, 并将其与分解的个体独立 Q 函数结合用于策略改进。本文提出的熵引导的极小极大值分解 (Entropy-guided minimax factorization, EGMF) 强化学习方法通过值分解降低计算复杂性, 并通过熵最大化增强算法的探索性能。

3) 在通用的仿真环境、多机器人博弈仿真场景和实体任务上进行测试, 并与其他基线方法进行比较, EGMF 算法以更少的样本实现更加卓越的性能。

1 相关工作

1.1 两团队零和马尔科夫博弈强化学习

许多研究工作将两团队零和多智能体博弈简化为二人零和多智能体博弈进行求解。这些工作主要基于策略种群^[11, 18], 如策略空间响应预言 (Policy space response oracles, PSRO) 方法, 其主要的改进方向包括增加其种群的多样性^[19]、提高其训练效率^[20-21], 以及引入不局限于寻找纳什均衡的新颖解决方案^[22-24]。此外, 通过策略种群算法处理队间对抗和多智能体强化学习方法处理队内合作, 一些算法在两团队零和马尔科夫博弈中取得显著的性能提升, 如弹性对抗值分解对手比率 (Resilient adversarial value decomposition with antagonist-ratios, RADAR)^[15] 和团队策略空间响应预言 (Team-PSRO)^[16] 等。然而这些方法存在一定的不足。首先, 在训练获取新策略时, 先前迭代交互产生的数据会被丢弃, 导致这类算法的数据利用效率低下; 其次, 基于策略种群的算法需要额外的计算资源来计算元博弈和经验收益评估。

其他研究工作着重于研究团队内合作及其他相关的挑战, 如对抗性团队马尔科夫博弈, 或者更高效的数据利用率算法研究。独立策略梯度最大 (Independent policy gradient max, IPGMAX)^[25] 和经验策略优化 (Empirical policy optimization, EPO)^[26] 等算法利用智能体个体的历史经验数据求解纳什均衡, 降低求解的计算复杂度。然而, 这些方法通常忽略团队内合作的重要性, 或在计算的复杂性上存在一定的局限性^[27]。总之, 解决两团队零和多智能体博弈的现有方法各有其局限性, 有些方法数据利用率低, 有些方法未考虑团队内的信用分配, 还有一些只能处理特定动作空间任务。

1.2 值分解强化学习

值分解是基于集中式训练分布式执行 (Centralized training decentralized execution, CTDE)^[28] 范式的多智能体强化学习中具有代表性的一类算法, 特别是在合作多智能体任务中。如“个体-全局-最大 (Individual-global-max, IGM)”^[29] 准则所述, 联合贪婪动作与个体贪婪动作之间的等价性具有重要意义。这些值分解方法通过将多智能体系统联合动作的 Q 函数作为基于局部观测的个

体 Q 函数的组合, 确保 IGM 准则的一致性^[30-31]. 值分解方法中的策略通常基于 Q 值, 仅限于处理离散动作场景. 此外, 有研究工作将值分解扩展到在执行器-评估器 (Actor-critic, AC) 框架内的多智能体强化学习算法中^[32-33], 用于处理连续动作空间任务. 虽然这些方法在合作 MARL 中表现出显著的效果, 但如何扩展应用到团队对抗任务中是一个挑战.

1.3 最大熵强化学习

标准的强化学习目标函数是最大化期望累积奖赏. 最大熵强化学习与之不同, 其旨在最大化回报的同时最大化策略的熵, 即采用更加随机的动作, 使得智能体具有更强的探索能力^[34]. 实践结果证明, 最大熵强化学习目标同时还改善了强化算法的学习速度和稳定性^[35]. 分布柔性执行器-评估器 (Distributional soft actor-critic, DSAC)^[36] 作为柔性执行器-评估器 (Soft actor-critic, SAC)^[35] 的变体, 针对连续动作空间下的离线强化学习方法, 通过减轻 Q 值的过估计问题来提高策略性能, 同时保持状态-动作回报的方差在合理范围内, 直接学习连续回报分布, 以解决梯度爆炸和消失问题. 因子分解最优联合策略 (Factorizing optimal joint policy, FOP)^[33] 将最大熵强化学习引入合作的多智能体强化学习中, 并将最优联合策略分解为个体策略. 然而, 目前将最大熵强化学习应用于两团队零和马尔科夫博弈问题尚未得到解决.

2 问题描述

本文将两个团队分别定义为红方和蓝方, 使用以下八元组 $\langle \mathcal{S}, \mathcal{N}, \mathcal{M}, \mathcal{A}, \mathcal{B}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ 对两团队零和马尔科夫博弈问题^[37] 建模. 其中, $\mathcal{S}$ 代表状态空间; $\mathcal{N} = \{1, \dots, n\}$ 和 $\mathcal{M} = \{1, \dots, m\}$ 分别是红方和蓝方团队中的有限智能体集合; $\mathcal{A} = \{\mathcal{A}_i\}_{i=1, 2, \dots, n}$ 和 $\mathcal{B} = \{\mathcal{B}_j\}_{j=1, 2, \dots, m}$ 分别表示红方和蓝方可用的动作集合. $\mathcal{P}(s'|s, \mathbf{a}, \mathbf{b}) : \mathcal{S} \times \mathcal{A} \times \mathcal{B} \rightarrow \mathcal{S}$ 是多智能体系统在状态 $s \in \mathcal{S}$ 下采取联合动作 $\mathbf{a} = (a_1, a_2, \dots, a_n)$ 和 $\mathbf{b} = (b_1, b_2, \dots, b_m)$ 后, 状态转移到 $s' \in \mathcal{S}$ 的条件概率. 若在 t 时刻的状态为 s_t , 则 $s' = s_{t+1}$ 表示下一时刻的状态. 同理, 若在 t 时刻红方智能体 i 的动作为 $a_{i,t}$, 蓝方智能体 j 的动作为 $b_{j,t}$, 则 $a'_{i,t} = a_{i,t+1}$ 和 $b'_{j,t} = b_{j,t+1}$ 分别表示其下一时刻的动作. 奖赏函数 $\mathcal{R}$ 确定红方在每个时间步接收的奖赏 $r = \mathcal{R}(s, \mathbf{a}, \mathbf{b})$, 反之, 对蓝方智能体而言是惩罚. $\gamma \in (0, 1)$ 是折扣因子.

对于双方的每个智能体, 它们的策略是将状态

映射到动作分布, 表示为 $\pi_i(a_i|s)$ 和 $\mu_j(b_j|s)$. 红方智能体的目标是最大化期望累积奖赏, 而蓝方智能体的目标是最小化红方智能体的期望累积奖赏, 即

$$\max_{\pi_1, \dots, \pi_n} \min_{\mu_1, \dots, \mu_m} \mathcal{R} = \sum_{t=0}^{\infty} \gamma^t r_t$$

在马尔科夫博弈问题中, 所有智能体都可以获得全局状态用于决策. 在其他一些部分可观测的多智能体问题中, 智能体只能获取局部观测, 无法感知全局状态. 为提升决策准确度, 通常利用循环神经网络或堆叠历史观测等方法作为策略输入, 从一段时刻的局部观测中尽可能推断全局信息, 解决局部观测的问题^[33, 38]. 为方便后续理论分析, 本文以马尔科夫博弈作为研究对象, 智能体根据全局状态进行策略决策, 但是所提算法通过上述方式很容易扩展到多智能体局部观测场景. 在多智能体强化学习环境中, 定义联合 Q 函数用于评估联合策略, 即

$$Q_{\text{tot}}(s, \mathbf{a}, \mathbf{b}) = \mathbb{E}_{\pi, \mu} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

3 熵引导的极小极大值分解算法

本节提出的熵引导的极小极大值分解 (EGMF) 方法以学习两团队零和马尔科夫博弈的双方智能体的策略, 为每个智能体找到优势策略, 实现两个团队的零和目标, 并尽可能地最大化策略的熵, 以避免陷入局部最优. 首先针对奖赏信号, 通过基于极小极大值分解的方法评估红方和蓝方智能体的策略. 极小极大值分解框架将复杂的两团队联合 Q 函数分解为两组个体的独立 Q 函数, 并仍然保持两个团队的极小极大化特性. 然后, 个体策略的优化被简化为仅与个体独立 Q 函数相关. 为增强在线探索, 本文考虑熵在策略改进中的作用, 通过统计策略在时间域累加的熵值来评估策略的熵, 并将其与独立 Q 函数结合提升策略. EGMF 算法在策略评估、熵评估和策略改进之间交替进行, 其整体框架如图 1 所示.

3.1 策略评估

在两团队零和马尔科夫博弈中, 考虑红方智能体的策略 $\pi_1, \dots, \pi_n$, 蓝方智能体策略 $\mu_1, \dots, \mu_m$, 策略评估中联合 Q 函数满足

$$Q_{\text{tot}}(s, \mathbf{a}, \mathbf{b}) = r + \gamma \mathbb{E} \left[\sum_{\mathbf{a}'} \sum_{\mathbf{b}'} \pi(\mathbf{a}'|s') \mu(\mathbf{b}'|s') Q_{\text{tot}}(s', \mathbf{a}', \mathbf{b}') \right] \quad (1)$$




图1 EGMF 的方法架构 (EGMF 通过联合极小极大 Q 函数分解框架进行策略评估, 分解的个体独立 Q 函数与熵评估函数结合用于策略改进)

Fig.1 The architecture of EGMF (EGMF evaluates policies through the joint minimax Q function decomposition framework, and combines the factorized individual Q function with the entropy evaluation function for policy improvement)

直接使用神经网络拟合 Q_{tot} 主要存在以下两个问题: 1) 当两组智能体的数量增长时, 联合动作空间呈指数级增长, 拟合高维函数需要大量样本; 2) 由于零和设置^[39]与信用分配问题^[40], 即使成功拟合联合 Q 网络, 使用 Q_{tot} 更新双方智能体的策略仍然可能会导致学习不稳定。

值分解方法是处理合作多智能体强化学习领域中高维度问题的常见方法^[29], 其中一组智能体共享相同的奖赏并协作完成任务。与构建对应于联合动作空间的复杂联合 Q 网络不同, 值分解通过简单的结构构建个体独立 Q 网络, 并通过以下方式混合个体值 Q_i :

$$Q_{\text{tot}}(s, \mathbf{a}) = \text{mix}(Q_1, \dots, Q_n | s)$$

QMIX 是值分解的一个典型例子。它采用混合网络满足 IGM 准则:

$$\frac{\partial Q_{\text{tot}}}{\partial Q_i} \geq 0, \quad \forall i \in \mathbf{N}$$

确保局部最优动作 $\arg \max_{a_i} Q_i(\cdot, a_i)$ 与其组成全

局最优联合动作 $\arg \max_{\mathbf{a}} Q_{\text{tot}}(\cdot, \mathbf{a})$ 的一致性。受合作式多智能体强化学习中值分解的最新进展启发^[29-30], 引入“个体-全局-极小极大 (Individual-global-minmax, IGM)”准则^[17], 将联合 Q_{tot} 分解为两组个体独立 Q 函数: $Q_1^{\text{Pro}}, \dots, Q_n^{\text{Pro}}$ 和 $Q_1^{\text{Ant}}, \dots, Q_m^{\text{Ant}}$, 分别对应红方和蓝方:

$$Q_{\text{tot}} = \text{mix} \left(\{Q_i^{\text{Pro}}\}_{i=1, \dots, n}, \{Q_j^{\text{Ant}}\}_{j=1, \dots, m} | s, \phi \right)$$

其中, ϕ 表示混合网络的所有参数。混合网络的示意图如图 1(c) 所示。每个 $Q_i^{\text{Pro}}(s, a_i)$ 和 $Q_j^{\text{Ant}}(s, b_j)$ 都由个体独立 Q 网络近似, 该网络以全局状态 (或分布式设置中的局部观测) 和动作作为输入, 并输出个体独立 Q 值, 其参数分别用 ϕ_i^{Pro} 和 ϕ_j^{Ant} 表示。混合网络将两组值作为输入结合在一起, 以基于全局状态的超网络确定其网络参数。为保证红方和蓝方之间的双方零和关系, 超网络通过以下方式强制实现 Q_{tot} 与输入 Q_i^{Pro} 和 Q_j^{Ant} 之间的单调性属性:

¹ 红方 (Proponents, Pros), 蓝方 (Antagonists, Ants)

$$\frac{\partial Q_{\text{tot}}}{\partial Q_i^{\text{Pro}}} \geq 0, \forall i, \quad \frac{\partial Q_{\text{tot}}}{\partial Q_j^{\text{Ant}}} \leq 0, \forall j \quad (2)$$

以上不等式可以通过在混合网络中设置权重的绝对值,并在网络输入之前对 Q_j^{Ant} 的符号进行取反实现. 在满足 IGMM 准则的条件下,红方可以通过选择最大化其 Q_i^{Pro} 的策略来增大联合 Q_{tot} ,而蓝方可以通过选择最大化其 Q_j^{Ant} 的策略来减小联合 Q_{tot} 的值,以此来实现红方和蓝方之间的零和关系.

给定一个数据集 $\mathcal{D} = (s, \mathbf{a}, \mathbf{b}, r, s')$, 对于 $\pi_1, \dots, \pi_n$ 和 $\mu_1, \dots, \mu_m$ 的策略评估可以通过最小化评估器损失来实现:

$$\mathcal{L}_c = \mathbb{E}_{\mathcal{D}}[y - \text{mix}(\{Q_i^{\text{Pro}}(s, a_i)\}, \{Q_j^{\text{Ant}}(s, b_j)\} | s, \phi)]^2 \quad (3)$$

其中,

$$y = r + \gamma \times \text{mix}(\{Q_i^{\text{Pro}}(s', a'_i)\}, \{Q_j^{\text{Ant}}(s', b'_j)\} | s', \hat{\phi}),$$

$$a'_i \sim \pi_i(\cdot | s'), b'_j \sim \mu_j(\cdot | s')$$

目标网络参数 $\hat{\phi}$ 在训练期间保持平滑跟踪 ϕ :

$$\hat{\phi} \leftarrow \rho \hat{\phi} + (1 - \rho) \phi$$

其中, ρ 表示平滑因子. 在线训练期间,数据集 $\mathcal{D}$ 可以使用经验池代替,其中包含两个团队智能体在博弈环境中相互对抗产生的经验轨迹.

本文中策略的学习是受动作值函数 Q 引导的,独立的 Q 函数是通过联合 Q 函数极小极大值分解学习得到的,联合 Q 函数是集中式的学习,起到合作与对抗目的的作用,所以通过极小极大值分解学习独立 Q 函数并引导策略学习,可以实现团队策略之间的合作性和对抗性.

3.2 熵评估

算法在策略评估阶段获取分解的独立 Q 函数后,正反双方就可以分别优化其个体策略,以最大化相应的个体独立 Q 值. 然而,在线学习的早期阶段,由于样本数量和训练不足,评估结果并不准确. 利用不准确的 Q 函数过度优化策略可能会导致策略性能更差. 因此,保持策略熵有利于保持动作分布的多样性和探索未访问的样本空间.

在线强化学习中,保持策略的熵可以稳定学习过程并避免策略在早期阶段陷入局部最优. 最大熵强化学习^[41] 致力于通过确定一种既能最大化期望累积奖赏,又能最大化策略熵的最优策略来增强探索:

$$\mathcal{R}(\pi) = \sum_{t=0}^{\infty} \mathbb{E}_{\pi} [r(s_t, a_t) + \alpha h(\pi(\cdot | s_t))]$$

其中, $h(p(\cdot)) = -\sum_x p(x) \log p(x)$, α 是权重系数. 引入熵项可以引导智能体增大其动作分布的多样性.

SAC^[35] 作为经典的极大熵强化学习算法,算法优化过程在策略评估和策略提升之间进行迭代. 策略评估的计算式为

$$Q(s, a) = r + \gamma(Q(s', a') - \alpha \log(\pi(a' | s'))), a' \sim \pi(s')$$

策略提升的计算式为

$$\pi = \arg \max_{\pi} \sum_a \pi(a | s) (Q(s, a) - \alpha \log(\pi(a | s)))$$

考虑到个体独立 Q 值和策略熵在时间域内的影响,红方 i 的策略应根据

$$\max_{\pi_i} \sum_{a_i} \pi_i(a_i | s) Q_i^{\text{Pro}}(s, a_i) + \alpha \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t h(\pi_i(\cdot | s_t)) | s_0 = s \right] \Rightarrow$$

$$\max_{\pi_i} \alpha h(\pi_i(\cdot | s)) + \sum_{a_i} \pi_i(a_i | s) \times (Q_i^{\text{Pro}}(s, a_i) + \alpha H_i^{\text{Pro}}(s, a_i)) \quad (4)$$

进行优化. 其中, $H_i^{\text{Pro}}(s, a_i)$ 表示从 $t = 1$ 到 ∞ 期间在初始状态 $s_0 = s$, 动作 $a_{0,i} = a_i$ 的轨迹上的策略熵的期望总和:

$$H_i^{\text{Pro}}(s, a_i) = \mathbb{E} \left[\sum_{t=1}^{\infty} \gamma^t h(\pi_i(\cdot | s_t)) | s_0 = s, a_{0,i} = a_i \right] \quad (5)$$

根据 Bellman 方程^[42], 上述方程可以用递归方式重写为

$$H_i^{\text{Pro}}(s, a_i) = \mathbb{E} \left[\gamma h(\pi_i(\cdot | s')) + \gamma \sum_{a'_i} \pi_i(a'_i | s') H_i^{\text{Pro}}(s', a'_i) \right] \quad (6)$$

其中, $\sum_{a'_i} \pi_i(a'_i | s') H_i^{\text{Pro}}(s', a'_i)$ 表示下一时刻熵评估的期望.

因此,基于神经网络建立一个熵评估网络用于近似参数化的 H_i^{Pro} ,其参数为 ω_i^{Pro} ,且损失函数定义为

$$\mathcal{L}_e = \mathbb{E}_{\mathcal{D}} [y - H_i^{\text{Pro}}(s, a_i | \omega_i^{\text{Pro}})] \quad (7)$$

其中

$$y = -\gamma \log \pi_i(a'_i | s') + \gamma H_i^{\text{Pro}}(s', a'_i | \omega_i^{\text{Pro}}), a'_i \sim \pi_i(\cdot | s')$$

其中, ω_i^{Pro} 表示目标熵网络的参数,其在训练期间

基于平滑因子 ρ 保持平滑跟踪熵网络的参数 ω , 即

$$\hat{\omega} \leftarrow \rho\hat{\omega} + (1 - \rho)\omega$$

同理, 对于蓝方智能体 j 的策略 μ_j , 其熵的期望总和可以通过一个网络 $H_j^{\text{Ant}}(\cdot|\omega_j^{\text{Ant}})$ 近似, 并通过最小化类似于式 (7) 中定义的损失函数进行训练.

3.3 策略提升

根据红方智能体 i 的个体策略评估 Q_i^{Pro} 和熵评估 H_i^{Pro} , 遵循式 (4), 一个新的策略 π'_i 应该同时最大化期望回报与熵的和. 因此, 本文问题的最优解的闭合形式为

$$\pi'_i(s, a_i) \propto \exp(Q_i^{\text{Pro}}(s, a_i) + \alpha H_i^{\text{Pro}}(s, a_i))$$

引入最大熵可能导致更新波动, 使得训练过程中的样本效率下降. 但其可增加探索性使智能体避免陷入局部最优, 在求解博弈空间较大的任务时能够尽快跳出局部并继续寻优, 也在一定程度上可以提高收敛速度. 因此, 本文通过权重系数 α 更好地利用探索性与收敛性以实现更为有效的联合策略优化.

在实践中, 本文更倾向于一组可以参数化、可控的策略, 例如对于连续动作空间可使用高斯分布, 对于离散动作空间可使用分类分布. 策略改进即是找到一个新的策略:

$$\pi'_i =$$

$$\arg \min_{\pi \in \Pi} D_{\text{KL}}\left(\pi(\cdot|s) \left\| \frac{\exp(Q_i^{\text{Pro}}(s, \cdot) + \alpha H_i^{\text{Pro}}(s, \cdot))}{Z(s)}\right.\right)$$

其中, $Z(\cdot)$ 是归一化项.

对于连续动作的情况, 策略通常由高斯分布表示, 并使用神经网络重新参数化 $a_i = f_{\theta_i^{\text{Pro}}}(\epsilon; s)$, 其中 $\epsilon \sim N(0, I)$, θ_i^{Pro} 表示网络参数. 策略改进的目标可以重新表述为最小化 SAC 损失^[35], 即

$$\mathcal{L}_a = E_{s \sim \mathcal{D}, \epsilon \sim N} \left[\alpha \log(\pi_i(f_{\theta_i^{\text{Pro}}}(\epsilon; s)|s, \theta_i^{\text{Pro}})) - \right. \\ \left. Q_i^{\text{Pro}}(s, f_{\theta_i^{\text{Pro}}}(\epsilon; s)) - \alpha H_i^{\text{Pro}}(s, f_{\theta_i^{\text{Pro}}}(\epsilon; s)) \right] \quad (8)$$

对于离散动作的情况, 策略通过神经网络以分类分布的形式表达, 训练目标为最小化以下损失函数:

$$\mathcal{L}_a = E_{s \sim \mathcal{D}} \left[\sum_{a_i} \pi_i(a_i|s, \theta_i^{\text{Pro}}) \times \right. \\ \left. (\alpha \log(\pi_i(a_i|s, \theta_i^{\text{Pro}})) - \right. \\ \left. Q_i^{\text{Pro}}(s, a_i) - \alpha H_i^{\text{Pro}}(s, a_i)) \right] \quad (9)$$

对于蓝方智能体 j 的策略 μ_j , 策略改进的目标与式 (4) 相同, 但需要将个体独立 Q 函数和熵函数替换为 Q_j^{Ant} 和 H_j^{Ant} , 在式 (8) 或式 (9) 中的损失函数也进行相应的替换.

EGMF 的整体训练过程如算法 1 所示. 在博弈环境中部署两组智能体的策略, 两组智能体利用当前策略进行博弈并与环境进行交互, 在线收集交互数据并保存到回放经验池中. EGMF 通过利用历史交互数据, 在策略评估、熵评估和策略改进之间进行迭代, 更新评估网络和策略网络. 经过一定的迭代更新后, 红方智能体和蓝方智能体分别学习得到两组优势的策略, 以便其能够与队友合作并与对手对抗. 本文与 FM3Q^[17] 算法同属于基于极小极大值分解框架的方法, FM3Q 算法已证明基于极小极大值分解框架方法的收敛性, 因此 EGMF 也可以保证其全局收敛性. 同时, 基于 Q 函数的评估器本身具有天然的异策略优势, 因此利用 FM3Q 全经验池机制进行训练, 可以大幅提升数据利用率, 在高采样成本的任务中快速找到优势的分布式策略.

算法 1. 熵引导的极小极大值分解算法

- 1: 输入: Q 函数网络参数 ϕ , 熵函数网络参数 ω , 策略网络参数 θ , 经验回放池 $\mathcal{D}$, 平滑因子 ρ , 优化步数 T
- 2: 将目标网络参数设置为与训练网络相同 $\hat{\phi} \leftarrow \phi$, $\hat{\omega} \leftarrow \omega$
- 3: **repeat**
- 4: 获取状态 s 并选择动作 $a_i \sim \pi_i(s|\theta_i^{\text{Pro}})$, $b_j \sim \mu_j(s|\theta_j^{\text{Ant}})$
- 5: 执行动作并获取下一个状态 s' 和奖赏 r , 将 $(s, \mathbf{a}, \mathbf{b}, s', r)$ 存入 $\mathcal{D}$
- 6: **if** $|\mathcal{D}|$ 大于最小经验池数据量 **then**
- 7: **for** $i = 1, \dots, T$ **do**
- 8: 从 $\mathcal{D}$ 中进行批数据采样
- 9: 根据式 (3), (7), (8) 或 (9), 通过最小化损失函数 $\mathcal{L}_c$, $\mathcal{L}_e$, $\mathcal{L}_a$ 更新 ϕ , ω , θ
- 10: 更新目标网络参数 $\hat{\phi} \leftarrow \rho\hat{\phi} + (1 - \rho)\phi$, $\hat{\omega} \leftarrow \rho\hat{\omega} + (1 - \rho)\omega$
- 11: **end for**
- 12: **end if**
- 13: **until** 收敛

EGMF 将联合极小极大 Q 函数分解为独立的 Q 函数, 然后基于独立的策略评估函数优化策略, 所以 EGMF 只需要在 $\mathcal{S} \times (n\mathcal{A} + m\mathcal{B})$ 空间中进行策略优化. 而直接计算联合极小极大 Q 函数并基于其进行策略优化, 需要在 $\mathcal{S} \times \mathcal{A}^n \times \mathcal{B}^m$ 空间中进行

寻优. 因此, EGMF 可极大地降低训练的复杂度.

4 实验结果与分析

4.1 实验设置

本文实验旨在验证和阐明以下几个方面: 1) 所提出的 EGMF 方法的适用性不受动作空间限制, 可以有效地处理离散和连续动作任务; 2) EGMF 在各种评估标准下优于基线方法; 3) EGMF 在实体机器人任务中表现出卓越性能.

为验证 EGMF 的有效性及其优越性, 在三个仿真场景 (分别包含离散和连续动作任务) 和一个实体机器人任务中进行实验验证, 如图 2 所示.




图 2 实验验证平台 (包括 Wimplepong 2v2、MPE 3v3、RoboMaster 2v2 和现实世界的 RoboMaster 2v2)
Fig.2 Experimental verification platform (including Wimplepong 2v2, MPE 3v3, RoboMaster 2v2 and real-world RoboMaster 2v2)

1) Wimplepong 2v2^[43]. 如图 2(a) 所示, 绿色和红色的球拍分别由两个团队控制, 白色的圆圈代表球. 在连续动作设置中, 每个团队内的两个智能体的输出进行加和然后应用到球拍上. 在离散动作设置中, 智能体采取下述三种动作之一: 向上移动、向下移动或原地待命. 本文将此场景中的离散动作任务和连续动作任务分别称为 Pong-D 和 Pong-C.

2) MPE 3v3^[44]. 如图 2(b) 所示, 三个蓝色智能体和三个红色智能体移动、碰撞并相互阻挡, 以使各自的队伍尽可能接近绿色目标. 在连续动作设置中, 每个智能体接收水平和垂直两个方向的力后进行移动. 在离散动作设置中, 每个智能体可以采取

下述五种动作之一: 向上或向下移动、向左或向右移动、静止. 本文将 MPE 的离散和连续动作任务分别标记为 MPE-D 和 MPE-C.

3) RoboMaster 2v2^[45]. 如图 2(c) 所示, 两个蓝色机器人与两个红色机器人在障碍物场地中进行对抗. 在连续动作设置中, 机器人确定需要到达的目的地的位置以及需要攻击的敌人. 在离散动作设置中, 机器人确定去哪个候选点 (4 个离散动作) 以及击中哪个对手 (2 个离散动作). 此场景下, 离散和连续动作任务分别标记为 RM-D 和 RM-C.

4) 现实世界的 RoboMaster 2v2^[45]. 如图 2(d) 所示, 是一个连续的真实世界 RoboMaster 2v2 实体机器人平台.

本文选择的对比算法有: RADAR^[15]、Team-PSRO^[16] 和 NXDO^[46], 它们是用来解决两团队零和马尔科夫博弈的流行方法. RADAR 通过将 SP (Self-play)^[18] 与值分解方法相结合来训练团队策略; Team-PSRO 在种群迭代过程中通过强化学习以学习对手团队的元策略的联合最佳响应, 在对抗中使用 PSRO^[11] 的机制, 在合作中使用合作多智能体强化学习的方法; NXDO 与 Team-PSRO 不同, 它在每个信息状态下混合最佳反应. 在 EGMF 和所有基线方法上运行所有实验, 并将每个实验重复 5 次以减少随机性的影响. 为公平起见, 在 RADAR、Team-PSRO 和 NXDO 的策略种群中使用因子分解的多智能体集中式策略梯度 (Factored multi-agent centralised policy gradients, FACMAC)^[32] 模型作为种群的个体, 并设置一些相同的超参数, 如网络和学习率. 此外, 在实验中, 本文中所有智能体均使用门控循环单元 (Gated recurrent unit, GRU) 将输入的局部观测信息处理为历史信息, 作为策略网络和评估网络的输入. 实验中所有方法的重要超参数如表 1 所示.

4.2 基于脚本的智能体作为评估

为评估不同算法学习到的策略, 实验环境中构建基于脚本的智能体, 并将学习过程中产生的策略与脚本智能体进行对抗测试. 在 Wimplepong 2v2 和 MPE 3v3 环境中, 基于脚本的智能体选择可以接近球的动作, 而在 RoboMaster 2v2 中, 智能体优先攻击生命值最低的单位. 对于 Wimplepong 2v2、MPE 3v3 和 RoboMaster 2v2, 使用了总共 12 k、12 k 和 80 k 个回合来训练 EGMF 和基线方法. 在 Wimplepong 2v2 和 RoboMaster 2v2 任务中, 智能体的性能通过胜率 (获胜局数与对抗实验局数的比率) 来评估, 而在 MPE 3v3 任务中, 智能体的性能

表 1 实验中所有方法的重要超参数
Table 1 Important hyperparameters of all methods in experiments

算法	超参数	名称	Wimblepong 2v2	MPE 3v3	RoboMaster 2v2
共用超参数	$n_episodes$	回合数	13000	13000	80000
	n_seeds	种子数	8	8	8
	γ	折扣因子	0.99	0.98	0.99
	hidden_layers	隐藏层	[64, 64]	[64, 64]	[128, 128]
	mix_hidden_dim	混合网络隐藏层	32	32	32
	learning_rate	学习率	0.0005	0.0005	0.0005
EGMF (本文)	buffer_size	经验池大小	400 000	40 000	400 000
RADAR ^[15] /Team-PSRO ^[16] /NXDO ^[46]	n_genes	迭代数	13	13	10
	ep_per_gene	单次迭代回合	1000	1000	80000
	batch_size	批大小	1000	1000	2000
	buffer_size	经验池大小	200 000	20 000	200 000

通过回报 (累积奖励) 来评估。

4.2.1 训练过程结果

在训练过程中, 所有方法的学习模型与脚本智能体对抗的结果如图 3 所示。

从图 3 中可以明显看出, EGMF 表现出最快的优化速度、最高的性能和与其他基线方法相比最小的方差。首先, 在六种环境中, EGMF 分别需要 1.5 k、

2.0 k、1.0 k、1.0 k、20 k 和 8.0 k 个回合来实现 0.5、0.5、15、15、0.5 和 0.5 的性能。相比之下, 基线方法需要至少 4.5 k、4.0 k、5.0 k、3.0 k、80 k 和 40 k 个回合才能在这六种环境中达到相同的性能水平, 即 EGMF 的优化速度是最优基线算法的 2~5 倍。实验结果表明, EGMF 可以使用更少的数据实现更好性能。此外, EGMF 在所有环境中与脚本智能体的对抗结果基本上一直处于领先状态, 其性能可以稳步提升并且最终稳定收敛于最佳性能。

4.2.2 最终测试结果

在算法完成训练后, 不同算法对同一组脚本智能体的结果如表 2 所示。实验结果显示, EGMF 表现明显优于其他算法。EGMF 在六个不同环境中对抗脚本智能体, 获得的性能均值分别约为 0.95、32.3、0.63、0.95、23.0 和 0.62。相比之下, 其他算法在三个环境中获得的最佳性能如下: NXDO 和 Team-PSRO 在 Pong-D 中达到 0.71, NXDO 在 MPE-D 中达到 24.1, 在 RM-D 中达到 0.45, 在 Pong-C 中达到 0.80, 在 MPE-C 中达到 23.0, 在 RM-C 中达到 0.61。在 MPE-C 任务中, 只有 NXDO 与 Team-PSRO 的结果与 EGMF 性能相当; 在 RM-C 任务中只有 NXDO 与 EGMF 的性能相当。实验结果表明, 通过值分解和最大熵技术, EGMF 能够找到一组在面对未知对手时具有优势合作对抗能力的策略。

4.2.3 与 FM3Q 方法对比结果

此外, 由于 FM3Q 算法只能应用于离散动作任务, 因此将 FM3Q 与 EGMF 仅在离散动作任务中进行对比。本节通过算法训练得到 EGMF 和 FM3Q 在不同任务和不同阶段的模型, 并将其与脚本智能




图 3 训练过程中与基于脚本的智能体进行对抗的结果
Fig.3 The results of playing against the scripted-based agents during the training process

表 2 训练结束后各个算法与基于脚本的智能体对抗的结果和循环赛交叉对抗的结果
Table 2 Performance of all methods at the end of training by playing against the scripted-based agents, and the cross-play results of round-robin returns

指标	算法	场景					
		Pong-D	MPE-D	RM-D	Pong-C	MPE-C	RM-C
与固定脚本对抗	EGMF (本文)	0.95±0.01	32.3±1.0	0.63±0.03	0.95±0.02	23.0±0.5	0.62±0.03
	RADAR ^[15]	0.52±0.11	16.3±5.2	0.35±0.02	0.58±0.03	12.5±5.1	0.52±0.02
	Team-PSRO ^[16]	0.71±0.04	21.2±3.4	0.33±0.01	0.71±0.06	22.1±2.9	0.54±0.03
	NXDO ^[46]	0.71±0.10	24.1±1.6	0.45±0.02	0.80±0.05	23.0±0.4	0.61±0.01
循环赛结果	EGMF (本文)	0.92±0.01	12.1±0.3	0.90±0.02	0.91±0.02	7.8±2.2	0.72±0.01
	RADAR ^[15]	0.45±0.02	-2.4±2.5	0.45±0.04	0.43±0.02	-1.8±1.9	0.50±0.01
	Team-PSRO ^[16]	0.53±0.02	1.9±1.9	0.49±0.01	0.56±0.04	-3.7±2.8	0.55±0.01
	NXDO ^[46]	0.51±0.02	2.5±1.2	0.51±0.02	0.63±0.02	2.9±1.9	0.58±0.02

注: 粗体表示各算法在不同场景下的最优结果。

体进行对抗并统计胜率或得分 (以下统称性能)。表 3 中“回合 (0.6)”表示与脚本智能体进行对抗的性能达到 0.6 所需的训练回合数, “性能”则表示在训练结束后方法能达到的结果。EGMF 和 FM3Q 在 Pong-D、MPE-D 和 RM-D 任务中的性能相当。在 MPE-D 任务中, EGMF 不仅在最终性能上优于 FM3Q, 而且能够较快地获得次优的性能, 即 EGMF 在 2.8 k 个回合时获得了 25 的性能, 而 FM3Q 在 3.6 k 个回合时才获得相同的性能。但在 RM-D 任务中 EGMF 的性能要略逊于 FM3Q, EGMF 的最终性能为 0.63, FM3Q 的最终性能为 0.68, 而且 EGMF 在 35 k 个回合时获得了 0.6 的性能, 而 FM3Q 仅在 19 k 个回合时就获得相同的性能。但是, 在 Pong-D 任务中, EGMF 和 FM3Q 的性能相当: EGMF 的最终性能均值为 0.95, FM3Q 的最终性能均值为 0.96, 但 EGMF 的胜率方差明显更小; 此外, EGMF 和 FM3Q 获得 0.8 的性能分别需要 3.0 k 和 3.1 k 个回合。这些结果表明, EGMF 在离散动作任务中的性能几乎与 FM3Q 相当, 但 FM3Q 算法只能处理离散动作任务。

4.3 可利用度评估

可利用度^[8]通常用于衡量策略与纳什均衡之间

的距离, 评估其是否容易被对手预测和利用。首先, 采用循环 (Round-robin, RR) 锦标赛^[47], 评估每种方法在与所有其他基准方法对抗中的可利用度。此外, 利用近似的纳什误差 (Approximate Nash-Conv)^[48]来估计在面对最佳反应时的可利用度。

循环锦标赛中每个参赛者都与其他所有参与者对抗, 获胜者将获得更高的分数。训练过程中模型的循环赛回报结果如图 4 所示。可以观察到, 在所有环境中, 无论是离散动作任务还是连续动作任务, EGMF 在循环赛回报指标方面都优于其他算法。在这些任务的训练后期阶段, EGMF 一直保持对基线方法的领先地位。同时还可以明显地看出, EGMF 展现出最快的优化速度和最高的循环赛回报。EGMF 几乎在所有环境的训练前期就可以保持领先, 只有在 MPE-C 中直到训练中后期才与其他对比算法拉开差距。

表 2 中的循环赛结果显示训练结束时的各个算法交叉对抗的循环赛回报。可以观察到, 在所有环境中, 无论是离散动作任务还是连续动作任务, EGMF 在循环赛回报指标上均优于所有对比算法。EGMF 在六个不同环境中交叉对抗的循环赛回报均值分别约为 0.92、12.1、0.90、0.91、7.8 和 0.72。

表 3 EGMF 和 FM3Q 与基于脚本的智能体对抗的结果
Table 3 Performance of EGMF and FM3Q by playing against the scripted-based agents

算法	Pong-D		MPE-D		RM-D	
	回合 (0.8)	性能	回合 (25)	性能	回合 (0.6)	性能
EGMF (本文)	3.0 k	0.95±0.01	2.8 k	32.3±1.0	35 k	0.63±0.03
FM3Q ^[17]	3.1 k	0.96±0.03	3.6 k	29.9±1.2	19 k	0.68±0.03

注: 粗体表示各方法在不同场景下的最优结果。




图4 训练过程中多种算法交叉对抗的循环赛回报

Fig.4 The cross-play results of RR returns throughout the training process

相比之下, 其他算法在三个环境中获得的最佳性能如下: Team-PSRO^[16] 在 Pong-D 中达到 0.53, NXDO^[46] 在 MPE-D 中达到 2.5, 在 RM-D 中达到 0.51, 在 Pong-C 中达到 0.63, 在 MPE-C 中达到 2.9, 在 RM-C 中达到 0.58. 因此, 可以推断出 EGMF 不仅在最终模型中实现了优越的性能, 而且还表现出更高的数据利用率.

接下来, 使用 NashConv 指标评估不同算法学习到的策略. 本节将两个团队简化为两个玩家, 一个团队的联合策略 σ_i 的可利用度 $e(\sigma_i)$ 表示当对手团队采取最佳响应时, 该策略比纳什均衡策略差多少. 形式化地, $e(\sigma_i) = u_i(\sigma_i^*, BR(\sigma_i^*)) - u_i(\sigma_i, BR(\sigma_i))$ ^[48], 其中 u_i 是玩家 $i = 1, 2$ 的效用函数, σ_i^* 是该团队纳什均衡策略, $BR(\sigma_i)$ 是对手团队的最佳响应. 由于第 1 项是固定的, 因此本节只关注第 2 项. 计算精确的 NashConv 需要获取准确的最佳响应, 这在当前的博弈任务中是无法精确获得的. 因此, 选择使用近似的 NashConv. 定期保存学习到的策略, 并将它们作为固定的对手来学习一个新的智能体. 由于对手策略是固定的, 问题可简化为合作多智能体强化学习, 并采用常见的 QMIX^[30] 作为对手策略的训练方法和框架, 曲线如图 5 所示. 图 5




图5 训练期间 EGMF 和基线方法的近似 NashConv 结果

Fig.5 The results of the approximate NashConv of EGMF and baselines during the training process

显示了 EGMF 的近似 NashConv 在训练过程中始终呈现下降趋势, 最终收敛到非常小的值. 此外, 与相同训练阶段的其他方法相比, EGMF 表现出更优越的性能. NXDO 和 Team-PSRO 同样呈现下降趋势, 它们的性能低于 EGMF, 但在相同的时间段内优于 RADAR.

4.4 优化过程分析

本节分析 EGMF 在训练阶段的性能优化趋势, 并使用交叉对抗平均回报的收益矩阵呈现结果. 图 6 展示了 EGMF 在所有任务中的收益矩阵. 其中, 收益为与种群中其他模型的胜率或回报的平均值. 横轴和纵轴表示训练步数.

以 Pong-D 为例, 实验中一共统计 13 个不同的训练阶段的模型. 这些模型通过循环赛相互对抗, 每个模型的平均胜率被视为相应的收益值. 红色方块表示胜利的实例, 深色表示更高的胜率. 相反, 蓝色方块代表失败的实例, 深色表示较低的胜率. 显然, 在这些矩阵的下三角部分, 红色方块的数量占绝大多数, 在同一行中, 左侧红色始终深于右侧红色, 由此可以推断出后期训练的模型优于早期训练的模型. 其中红色方块的数量逐渐增加, 表明后期




图6 EGMF方法在六种场景中的收益矩阵
Fig.6 Illustration of the payoff values of EGMF modules in the six scenarios

训练的模型在与早期训练的模型对抗时表现更好。因此,随着更多的数据和训练步骤,EGMF可以不断提高两个团队策略的合作对抗性能。

其中三个收益矩阵,如在Pong-C、MPE-D和MPC-C中所示,其下三角部分中仅有少数方格是蓝色的。尽管如此,这些蓝色的方格数量很少,表明后期训练的模型被早期训练的模型击败的可能性极低。具体来说,这三个收益矩阵的下三角部分中,这些蓝色方格分别仅占18/169,12/169和14/169。从上述实验结果可以得出结论,EGMF算法在训练过程中,后期学习得到的模型相比前期的模型,其性能更好。也就是说,EGMF算法模型的优化表现出了一定的单调性,随着训练的进行,模型的团队合作对抗性能逐渐提高。

4.5 消融实验

为研究最大熵对EGMF算法性能的影响,本节进行对应的消融实验。图7显示了针对最大熵消融的评估曲线,展示出最大熵消融前后两种方法与基于规则的智能体对抗的结果。在消融实验的设置




图7 最大熵消融实验过程中与基于脚本的智能体对抗的结果

Fig.7 The results with respect to the ablation of maximum entropy by playing against the scripted-based agents

中,将熵的影响系数 α 置为0。实验结果显示,在Pong-D中,添加最大熵的EGMF性能比没有最大熵的EGMF性能高出约5.6%,相应地,在MPE-D、MPE-C、RM-D和RM-C中,性能高出约6.7%、9.5%、5.0%和20.0%。在Pong-C中,两种方法性能相当,但从曲线中可以看出,添加最大熵的EGMF算法训练过程明显更加稳定。因此,在绝大多数环境中,添加最大熵的EGMF算法模型的性能优于没有最大熵的EGMF算法模型。结果表明,引入最大熵有助于避免EGMF陷入局部最优解。


此外,没有最大熵的极小极大值分解方法在六个环境中的性能分别为:0.92、0.95、30.0、21.2、0.61和0.52,而对比算法对应的最优性能分别为0.71、0.80、24.1、23.0、0.45和0.61,结果显示没有最大熵的极小极大值分解方法在四个环境中优于最优的对比算法,也就是说,没有最大熵的极小极大值分解方法也能学习到很好的团队合作对抗策略。

此外,本文通过可视化不同策略的行为,直观地展示最大熵优化如何提升策略的多样性^[49]。具体来说,本文在RM-D和RM-C两种环境中分别随


机选取五个状态, 计算智能体离散策略的策略分布以及连续策略的标准差, 并通过绘制来观察和分析引入最大熵前后的差异. 实验结果如图 8 所示, 结果显示最大熵方法鼓励策略在选择动作时具有更多的不确定性, 导致智能体采取不同的行动, 增强策略的多样性.

4.6 现实世界机器人场景中的验证

本文基于 NeuronsMAE^[46] 平台的实体机器人平台, 选择连续动作空间的实体机器人任务作为模型迁移测试环境, 使用域随机化优化识别 (Domain randomization optimization identification, DROID)^[50] 方法利用离线专家数据优化仿真器参数, 减少仿真和真实轨迹之间的误差, 使得仿真环境中的轨迹与真实环境的轨迹尽可能相同. 然后在更准确的动力学模型参数的仿真器中进行两团队合作对抗任务的训练, 最后将训练好的模型保存为 ONNX 格式, 并部署在蓝队机器人上, 与基于规则的红队机器人对抗. 图 9 展示了双方博弈过程的一部分. 其中, EGMF 算法模型部署在蓝队智能体上, 与基于规则的红队智能体进行对抗. 矩形和圆圈标记的是红队机器人, 而没有特定标记的表示蓝队机器人. 颜色方案表示机器人的健康状态, 绿色表示生命值健康的机器人, 黄色表示当前被集火的机器人, 红色表示已被消灭的机器人. 图上方中橘色圆的高度表示机器人的血量, 黑色圆表示当前的集火对象. 在所示的场景中: 图 9(a) 表示蓝队集中火力攻击生命值最低的敌人, 并正在移动形成前后夹击的阵型, 由于装甲板所受伤害值不同, 前后夹击可以最大化期望伤害; 图 9(b) 表示选择前后夹击对敌方机器人进行包夹, 以最大化预期伤害; 图 9(c) 表示当被集火的机器人死亡后, 蓝队将进攻目标转移



(a) RM-D 离散动作策略的熵
(a) Entropy of RM-D discrete action strategy



(b) RM-C 连续动作策略的标准差
(b) Standard deviation of RM-C continuous action strategy

图 8 最大熵优化提升策略的多样性
Fig.8 Maximum entropy optimization enhance the diversity of policy

到另一个剩余的敌方机器人; 图 9(d) 表示蓝队根据敌人的位置调整队形, 尽可能拉开攻击角度并持续攻击; 图 9(e) 表示敌人逃跑, 联合追击敌人. EGMF




图 9 基于 EGMF 模型部署在实体机器人连续任务中的演示

Fig.9 Demonstration of the continuous real-world robot task based on the EGMF model

在真实世界任务中的表现证明了其在实际应用中的可行性。

5 结束语

基于极小极大值分解的两团队零和博弈算法具有数据利用率高、性能优越的特点, 但往往受限于离散动作空间, 且容易收敛到局部最优。本文为高效处理不限动作空间的两团队零和马尔科夫博弈任务, 提出一种熵引导的极小极大值分解强化学习算法 EGMF。首先, 提出一种基于极小极大值分解的执行器-评估器框架, 在不限动作空间的任務中提升优化效率和算法性能。同时为避免在线学习过程收敛到局部最优, 引入最大熵使智能体可以更充分地探索状态空间。EGMF 利用历史交互数据, 在策略评估、熵评估和策略改进之间进行迭代更新。相关算法在仿真与实体实验场景验证了其优势, 尤其在与基于规则的智能体进行对抗的评估中, EGMF 的优化速度是最优基线算法的 2 ~ 5 倍。但是 EGMF 为保证训练稳定性, 在训练过程中使用的是全部的历史数据, 更加复杂的博弈任务中导致计算量非常大。因此, 未来我们将在现有算法中使用更加高效的经验回放机制。

References

- 1 Silver D, Huang A, Maddison C J, Guez A, Sifre L, van den Driessche G, et al. Mastering the game of Go with deep neural networks and tree search. *Nature*, 2016, **529**(7587): 484-489
- 2 Tang Zhen-Tao, Shao Kun, Zhao Dong-Bin, Zhu Yuan-Heng. Recent progress of deep reinforcement learning: From AlphaGo to AlphaGo Zero. *Control Theory and Applications*, 2017, **34**(12): 1529-1546
(唐振韬, 邵坤, 赵冬斌, 朱圆恒. 深度强化学习进展: 从 AlphaGo 到 AlphaGo Zero. 控制理论与应用, 2017, **34**(12): 1529-1546)
- 3 Sandholm T. Solving imperfect-information games. *Science*, 2015, **347**(6218): 122-123
- 4 Tang Z T, Zhu Y H, Zhao D B, Lucas S M. Enhanced rolling horizon evolution algorithm with opponent model learning: Results for the fighting game AI competition. *IEEE Transactions on Games*, 2023, **15**(1): 5-15
- 5 Guan Y, Afshari M, Tsiotras P. Zero-sum games between mean-field teams: Reachability-based analysis under mean-field sharing. In: Proceedings of the 38th AAAI Conference on Artificial Intelligence. Vancouver, Canada: AAAI, 2024. 9731-9739
- 6 Mathieu M, Ozair S, Srinivasan S, Gulcehre C, Zhang S T, Jiang R, et al. Starcraft II unplugged: Large scale offline reinforcement learning. In: Proceedings of the 35th Conference on Neural Information Processing Systems. Sydney, Australia: NeurIPS, 2021.
- 7 Ye D H, Liu Z, Sun M F, Shi B, Zhao P L, Wu H, et al. Mastering complex control in MOBA games with deep reinforcement learning. In: Proceedings of the 34th AAAI Conference on Artificial Intelligence. New York, USA: AAAI, 2020. 6672-6679
- 8 Littman M L. Markov games as a framework for multi-agent reinforcement learning. In: Proceedings of the 7th International Conference on International Conference on Machine Learning. San Francisco, USA: ACM, 1994. 157-163
- 9 Hu J L, Wellman M P. Nash Q-learning for general-sum stochastic games. *The Journal of Machine Learning Research*, 2003, **4**: 1039-1069
- 10 Zhu Y H, Zhao D B. Online minimax Q network learning for two-player zero-sum Markov games. *IEEE Transactions on Neural Networks and Learning Systems*, 2022, **33**(3): 1228-1241
- 11 Lanctot M, Zambaldi V, Gruslys A, Lazaridou A, Tuyls K, Pérolat J, et al. A unified game-theoretic approach to multiagent reinforcement learning. In: Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach, USA: ACM, 2017. 4193-4206
- 12 Chai J J, Chen W Z, Zhu Y H, Yao Z X, Zhao D B. A hierarchical deep reinforcement learning framework for 6-DOF UCAV air-to-air combat. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2023, **53**(9): 5417-5429
- 13 Li W F, Zhu Y H, Zhao D B. Missile guidance with assisted deep reinforcement learning for head-on interception of maneuvering target. *Complex and Intelligent Systems*, 2022, **8**(2): 1205-1216
- 14 Haarnoja T, Moran B, Lever G, Huang S H, Tirumala D, Humprik J, et al. Learning agile soccer skills for a bipedal robot with deep reinforcement learning. *Science Robotics*, 2024, **9**(89): Article No. eadi8022
- 15 Phan T, Belzner L, Gabor T, Sedlmeier A, Ritz F, Linnhoff-Popien C. Resilient multi-agent reinforcement learning with adversarial value decomposition. In: Proceedings of the 35th AAAI Conference on Artificial Intelligence. AAAI, 2021. 11308-11316
- 16 McAleer S, Farina G, Zhou G, Wang M Z, Yang Y D, Sandholm T. Team-PSRO for learning approximate TMECor in large team games via cooperative reinforcement learning. In: Proceedings of the 37th Conference on Neural Information Processing Systems. NeurIPS, 2023.
- 17 Hu G Z, Zhu Y H, Li H R, Zhao D B. FM3Q: Factorized multi-agent MiniMax Q-learning for two-team zero-sum Markov game. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 2024, **8**(6): 4033-4045
- 18 Bai Y, Jin C. Provable self-play algorithms for competitive reinforcement learning. In: Proceedings of the 37th International Conference on Machine Learning. PMLR, 2020. Article No. 52
- 19 Perez-Nieves N, Yang Y D, Shumbers O, Mguni D H, Wen Y, Wang J. Modelling behavioural diversity for learning in open-ended games. In: Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021. 8514-8524
- 20 Balduzzi D, Garnelo M, Bachrach Y, Czarnecki W, Pérolat J, Jaderberg M, et al. Open-ended learning in symmetric zero-sum games. In: Proceedings of the 36th International Conference on Machine Learning. Long Beach, USA: ICML, 2019. 434-443
- 21 McAleer S, Lanier J B, Fox R, Baldi P. Pipeline PSRO: A scalable approach for finding approximate Nash equilibria in large games. In: Proceedings of the 34th International Conference on Neural Information Processing Systems. Vancouver, Canada: ACM, 2020. Article No. 1699
- 22 Muller P, Omidshafiei S, Rowland M, Tuyls K, Pérolat J, Liu S Q, et al. A generalized training approach for multiagent learning. In: Proceedings of the 8th International Conference on Learning Representations. Addis Ababa, Ethiopia: ICLR, 2020.
- 23 Marris L, Muller P, Lanctot M, Tuyls K, Graepel T. Multi-agent training beyond zero-sum with correlated equilibrium meta-solvers. In: Proceedings of the 38th International Confer-

- ence on Machine Learning. PMLR, 2021. 7480–7491
- 24 Feng X D, Shumbers O, Wan Z Y, Liu B, McAleer S, Wen Y, et al. Neural auto-curricula in two-player zero-sum games. In: Proceedings of the 35th International Conference on Neural Information Processing Systems. NeurIPS, 2021. Article No. 268
 - 25 Anagnostides I, Kalogiannis F, Panageas I, Vlatakis-Gkaragkounis E V, McAleer S. Algorithms and complexity for computing Nash equilibria in adversarial team games. In: Proceedings of the 24th ACM Conference on Economics and Computation. London, UK: ACM, 2023. Article No. 89
 - 26 Zhu Y H, Li W F, Zhao M C, Hao J Y, Zhao D B. Empirical policy optimization for n -player Markov games. *IEEE Transactions on Cybernetics*, 2023, **53**(10): 6443–6455
 - 27 Luo G Y, Zhang H, He H B, Li J L, Wang F Y. Multiagent adversarial collaborative learning via mean-field theory. *IEEE Transactions on Cybernetics*, 2021, **51**(10): 4994–5007
 - 28 Lowe R, Wu Y, Tamar A, Harb J, Abbeel P, Mordatch I. Multi-agent actor-critic for mixed cooperative-competitive environments. In: Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach, USA: ACM, 2017. 6382–6393
 - 29 Sunehag P, Lever G, Gruslys A, Czarnecki W M, Zambaldi V, Jaderberg M, et al. Value-decomposition networks for cooperative multi-agent learning based on team reward. In: Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems. Stockholm, Sweden: ACM, 2018. 2085–2087
 - 30 Rashid T, Samvelyan M, de Witt C S, Farquhar G, Foerster J, Whiteson S. Monotonic value function factorisation for deep multi-agent reinforcement learning. *The Journal of Machine Learning Research*, 2020, **21**(1): Article No. 178
 - 31 Chai J J, Li W F, Zhu Y H, Zhao D B, Ma Z, Sun K W, et al. UNMAS: Multiagent reinforcement learning for unshaped cooperative scenarios. *IEEE Transactions on Neural Networks and Learning Systems*, 2023, **34**(4): 2093–2104
 - 32 Peng B, Rashid T, de Witt C A S, Kamienny P A, Torr P H S, Böhm W, et al. FACMAC: Factored multi-agent centralised policy gradients. In: Proceedings of the 35th International Conference on Neural Information Processing Systems. NeurIPS, 2021. Article No. 934
 - 33 Zhang T H, Li Y H, Wang C, Xie G M, Lu Z Q. FOP: Factorizing optimal joint policy of maximum-entropy multi-agent reinforcement learning. In: Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021. 12491–12500
 - 34 Haarnoja T, Tang H R, Abbeel P, Levine S. Reinforcement learning with deep energy-based policies. In: Proceedings of the 34th International Conference on Machine Learning. Sydney, Australia: PMLR, 2017. 1352–1361
 - 35 Haarnoja T, Zhou A, Abbeel P, Levine S. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In: Proceedings of the 35th International Conference on Machine Learning. Stockholm, Sweden: PMLR, 2018. 1856–1865
 - 36 Duan J L, Guan Y, Li S E, Ren Y G, Sun Q, Cheng B. Distributional soft actor-critic: Off-policy reinforcement learning for addressing value estimation errors. *IEEE Transactions on Neural Networks and Learning Systems*, 2022, **33**(11): 6584–6598
 - 37 Kalogiannis F, Panageas I, Vlatakis-Gkaragkounis E V. Towards convergence to Nash equilibria in two-team zero-sum games. In: Proceedings of the 11th International Conference on Learning Representations. Kigali, Rwanda: ICLR, 2023.
 - 38 Wang J H, Ren Z Z, Liu T, Yu Y, Zhang C J. QPLEX: Duplex dueling multi-agent Q-learning. In: Proceedings of the 9th International Conference on Learning Representations. ICLR, 2021.
 - 39 Condon A. On algorithms for simple stochastic games. *Advances in Computational Complexity Theory*, 1990, **13**: 51–72
 - 40 Zhou M, Liu Z Y, Sui P W, Li Y X, Chung Y Y. Learning implicit credit assignment for cooperative multi-agent reinforcement learning. In: Proceedings of the 34th International Conference on Neural Information Processing Systems. Vancouver, Canada: NeurIPS, 2020. Article No. 994
 - 41 Ziebart B D, Maas A, Bagnell J A, Dey A K. Maximum entropy inverse reinforcement learning. In: Proceedings of the 23rd AAAI Conference on Artificial Intelligence. Chicago, USA: AAAI, 2008. 1433–1438
 - 42 Bellman R. On the theory of dynamic programming. *Proceedings of the National Academy of Sciences of the United States of America*, 1952, **38**(8): 716–719
 - 43 Mnih V, Kavukcuoglu K, Silver D, Rusu A A, Veness J, Bellemare M G, et al. Human-level control through deep reinforcement learning. *Nature*, 2015, **518**(7540): 529–533
 - 44 Terry J K, Black B, Grammel N, Mario Jayakumar M, Ananth Hari A, Sullivan R, et al. PettingZoo: A standard API for multi-agent reinforcement learning. In: Proceedings of the 35th International Conference on Neural Information Processing Systems. NeurIPS, 2021. Article No. 1152
 - 45 Hu G Z, Li H R, Liu S S, Zhu Y H, Zhao D B. NeuronsMAE: A novel multi-agent reinforcement learning environment for cooperative and competitive multi-robot tasks. In: Proceedings of the International Joint Conference on Neural Networks (IJCNN). Gold Coast, Australia: IEEE, 2023. 1–8
 - 46 McAleer S, Lanier J, Wang K A, Baldi P, Fox R. XDO: A double oracle algorithm for extensive-form games. In: Proceedings of the 35th International Conference on Neural Information Processing Systems. NeurIPS, 2021. Article No. 1771
 - 47 Samvelyan M, Khan A, Dennis M, Jiang M Q, Parker-Holder J, Foerster J N, et al. MAESTRO: Open-ended environment design for multi-agent reinforcement learning. In: Proceedings of the 11th International Conference on Learning Representations. Kigali, Rwanda: ICLR, 2023.
 - 48 Timbers F, Bard N, Lockhart E, Lanctot M, Schmid M, Burch N, et al. Approximate exploitability: Learning a best response. In: Proceedings of the 31st International Joint Conference on Artificial Intelligence. Vienna, Austria: IJCAI, 2022. 3487–3493
 - 49 Cohen A, Yu L, Wright R. Diverse exploration for fast and safe policy improvement. In: Proceedings of the 32nd AAAI Conference on Artificial Intelligence. New Orleans, USA: AAAI, 2018. Article No. 351
 - 50 Tsai Y Y, Xu H, Ding Z H, Zhang C, Johns E, Huang B D. DROID: Minimizing the reality gap using single-shot human demonstration. *IEEE Robotics and Automation Letters*, 2021, **6**(2): 3168–3175



胡光政 中国科学院大学博士研究生。2016年、2019年分别获得北京理工大学学士和硕士学位。主要研究方向为深度强化学习和多机器人博弈。
E-mail: hugaungzheng2019@ia.ac.cn
(**HU Guang-Zheng** Ph.D. candidate of University of Chinese Academy of Sciences. He received his bachelor and master de-

degrees from Beijing Institute of Technology in 2016 and 2019, respectively. His research interest covers deep reinforcement learning and multi-robot game.)



朱圆恒 中国科学院自动化研究所副研究员. 2010 年获得南京大学自动化专业学士学位. 2015 年获得中国科学院自动化研究所控制理论和控制工程专业博士学位. 主要研究方向为深度强化学习, 博弈理论, 博弈智能和多智能体学习.

E-mail: yuanheng.zhu@ia.ac.cn

(ZHU Yuan-Heng Associate professor at the Institute of Automation, Chinese Academy of Sciences. He received his bachelor degree in automation from Nanjing University in 2010, and Ph.D. degree in control theory and control engineering from the Institute of Automation, Chinese Academy of Sciences in 2015. His research interest covers deep reinforcement learning, game

theory, game intelligence, and multiagent learning.)



赵冬斌 中国科学院自动化研究所研究员, 中国科学院大学教授. 分别于 1994 年、1996 年和 2000 年获得哈尔滨工业大学学士学位、硕士学位和博士学位. 主要研究方向为深度强化学习, 计算智能, 自动驾驶, 游戏人工智能, 机器人. 本文通信作者.

E-mail: dongbin.zhao@ia.ac.cn

(ZHAO Dong-Bin Professor at the Institute of Automation, Chinese Academy of Sciences and University of Chinese Academy of Sciences. He received his bachelor degree, master degree, and Ph.D. degree from Harbin Institute of Technology, in 1994, 1996, and 2000, respectively. His research interest covers deep reinforcement learning, computational intelligence, autonomous driving, game artificial intelligence, and robotics. Corresponding author of this paper.)